

上海交通大学在线考试诚信承诺书

SJTU Online Examination Honor Code Letter

考试不仅是对学习成效的检查，更是对道德品质的检验。自觉维护学校的考风考纪，营造公平、公正的考试环境是全体同学的责任和义务。特别在疫情防控的特殊时期，更应强化自律意识，恪守诚信，拒绝舞弊，做一名诚实守信的新时代大学生，用诚信的考试构筑诚信的人生。

Examination is the evaluation of both learning effect and morality. It is the responsibility and obligation of all students to consciously maintain the school's common examination practice, abide by the discipline and create a fair and just examination environment. Especially in the special period of epidemic prevention and control, we should strengthen the consciousness of self-discipline, abide by the integrity, refuse to cheat, be an honest and trustworthy college student in the new era, and build an honest life from the integrity test.

我郑重承诺 I solemnly promise:

(1) 本人将履约践诺，知行统一；遵从诚信规范，恪守学术道德；自尊自爱，自省自律。I will fulfill my promise, unify between knowledge and action, abide by the rules of integrity, academic ethics, be self-respected and self-disciplined.

(2) 在线考试过程中，自觉遵守学校和老师宣布的考试纪律（详见《上海交通大学本科生学生手册》中的《学生考试纪律规定》，沪交教【2019】28号），不剽窃，不违纪，不作弊。In the process of online examination, I will consciously abide by the examination discipline announced by the school and the teachers (see the regulations on student examination discipline in the undergraduate student handbook of Shanghai Jiao Tong University, HJJ [2019] No. 28), and do not plagiarize, violate discipline or cheat.

(3) 若违反相关考试规定和纪律要求，自愿接受学校的严肃处理或处分。In case of violation of relevant examination regulations and discipline, students shall bear the serious treatment or punishment from the school.

承诺人 Committed by:

李呈翰

(学号 Student No: 520021910279)

日期 Date (Y/M/D): 2023年1月5日



上海交通大学答题纸

(20²²至20²³学年第1学期)班级号 T2003702学号 520021910079姓名 李显翰课程名称 机器学习

成绩 _____

我承诺, 我将严格遵守考试纪律。

承诺人: 李显翰

题号										
得分										
批阅人(流水阅卷教师签名处)										

一、判断题:

1. ①不对 ②: 逻辑回归也是一种线性分类模型。

2. ①对 ②不对, ③还需要考虑前向传播

3. ①不对 ②: 各个特征 X 与 C 应该是条件独立的

④ ①=对

5. ①=对.

6. ①=对.

7. ①=对

8. ①=对 ②不对 ③应该增大 k

⑨ ①=不对

10. ①=对



上海交通大学 答题纸

(2022 至 2023 学年 第 1 学期)

520 02 1910279

二、简答题 课程名称 机器学习姓名 李显翰

① ①= 较高层级的词向量 对于学习层数更多, 因而相对于输入层而言更抽象, 有更强的表征学习能力。

②= 高层的词向量经过的 self-attention 层数更多, 更能体现一个句子的核心词语义, 更能体现句子的整体含义。

2、①= 语言模型指的是 一种给出一个 string 在一个给定“语言”中可能出现的概率的模型。

②= 第一种语法中提到的“大多数人读 qí, 就应该读 qí”, 实际上是“演化”说。

说的就是 语言模型的训练过程, 即根据前人的不同发音实际上对应了不同语义, 即对于 string “一骑红装坐妃子笑”, 以“qí”的语义计算出的 plw 要大于以“jī”的语义计算出的 plw , 故会选择 qí。

3、①= 用到迁移思想的模型: encoder-decoder 模型, 预训练模型。

②= encoder-decoder 模型本质上是一种 seq2seq 的生成模型, 但在其训练成功之后, 不仅可以接受文本语数据, 进行 seq 生成, 也可以接受音频等数据, 进行文本翻译, 因而完成了迁移学习。

③= 预训练模型: 首先对大量的同类文本数据进行学习、训练, 而后则可将模型用在涉及文本预测的大部分场合中, 完美满足迁移学习。



上海交通大学 答题纸

(2022 至 2023 学年 第 1 学期)

课程名称 机器学习52021910279
姓名 李呈翰

4. 自监督学习的例子:

① = 在 GAN 模型中, 生成器的目标是生成虚假图片来骗过判别器, 而判别器目标则是能够识别出生成器的假图片, 这个过程中, 生成器的 "label" 是 "判别器对 $G(z)$ 结果为 1", 判别器为 "对 $G(z)$ 结果为 0", 故为自监督学习。

② = K-Means 模型。在 K-Means 中, 对于选定的 center, 需对每个 data item 分配一个属于哪个 cluster 的 "label", 因而是一种自监督学习。

三、计算题:

1. 冲: ① 经过第一个卷积层后尺寸为:

$$\frac{(N+2P-F)}{\text{Stride}} + 1 = \frac{128+2*3-3}{2} + 1 = 64.5$$

② 尺寸为 $64 \times 64 \times 32$.

③ 经过第二个卷积层后, 尺寸为:

$$\frac{N-F}{\text{stride}} + 1 = \frac{64-4}{4} + 1 = 16$$

④ 最终输出的 feature map 尺寸为 $16 \times 16 \times 32$ 

上海交通大学 答题纸

(2022 至 2023 学年 第 1 学期)

课程名称 机器学习

520221910279
姓名 李呈翰

$$2. \text{ 求 } \frac{\partial L}{\partial w_1} = \frac{\partial L}{\partial s_1} \cdot \frac{\partial s_1}{\partial w_1}, = \lambda_1 \frac{\partial L}{\partial s_1}, \frac{\partial L}{\partial s_1} \text{ 为后项, 由 BP 可知:}$$

$$\frac{\partial L}{\partial s_1} = \frac{\partial L}{\partial h_1} \cdot \frac{\partial h_1}{\partial s_1} = \sigma(s_1)(1 - \sigma(s_1)) \cdot \frac{\partial L}{\partial h_1}, \frac{\partial L}{\partial h_1} \text{ 为后项, 由 BP:}$$

$$\frac{\partial L}{\partial h_1} = \frac{\partial L}{\partial s_3} \cdot \frac{\partial s_3}{\partial h_1} = w_5 \frac{\partial L}{\partial s_3}, \frac{\partial L}{\partial s_3} \text{ 为后项, 由 BP 可知:}$$

$$\frac{\partial L}{\partial s_3} = \frac{\partial L}{\partial y} \cdot \frac{\partial y}{\partial s_3} = \sigma(s_3)(1 - \sigma(s_3)) \cdot 2|\hat{y} - y|$$

$$\therefore \frac{\partial L}{\partial w_1} = \hat{y} = w_5 \sigma(w_5 \sigma(w_1 x_1 + w_2 x_2) + w_6 \sigma(w_3 x_3 + w_4 x_4)) \\ = 0.57867.$$

$$\therefore \frac{\partial L}{\partial w_5} = \frac{\partial L}{\partial s_3} = 0.3836, \frac{\partial L}{\partial h_1} = -7.672 \times 10^{-3},$$

$$\frac{\partial L}{\partial s_1} = -1.28384 \times 10^{-3},$$

$$\therefore \frac{\partial L}{\partial w_1} = 8.9869 \times 10^{-4}$$



上海交通大学答题纸

(20²²至20²³学年第1学期)

课程名称

机器学习

2022/10/27
姓名 李星翰

图四.

1. ①数据收集处理: 使用已收集到的100万张图片, 对其通过添加噪声, 降采样等方式, 对图片进行降低分辨率处理, 并将数据处理成尺寸相同的图片。并将 data 分为 train set 和 validation set.
- ②模型结构: 具体模型应与 Unet 右半部分相似, 即对输入的低分辨率图片进行 up sampling, 并在每次 up sampling 之后通过几次卷积提取特征, 最终获取目标尺寸的高分辨率图片。
- ③损失函数: 将得到图片与 label 图片 (即预先收集到的图片) 对比, 记目标图片分辨率为 r , 获取图片分辨率为 y , 则 loss function $= -r \log y + -(1-r) \log (1-y)$, 即 cross-entropy.
- ④优化方法: 使用反向传播进行优化。
- ⑤模型预测: 对于 validation set 中 data 作为 input, 检测并获取图片的分辨率。



上海交通大学答题纸

(20²²至20²³学年第1学期)

520021910279

课程名称 机器学习姓名 李显翰

2.11: ①=数据收集处理: 收集大量文本语言数据(如从维基百科等), 如收集100万条。之后对于获取的 string 进行 one-hot 以及 word-embedding 处理。并对每个 string 添加 position-encoding 处理。分为 train/validation

并添加 label ②=模型结构: ~~不使用 encoder-decoder 模型, 如 Transformer~~ 使用 ~~transformer decoder~~ decoder. (self-attention)

③=损失函数: 对于预测结果的每一位, 将其对应 one-hot 与 label 进行均方差处理, 即使用 MSE 作为损失函数, $L = \sum_{i=1}^n \frac{1}{n} \|r - y\|^2$ 。

④=训练(优化方法): 使用 BPTT (back propagation through time) 进行参数调整及优化, 并可使用 LSTM 防止过拟合/消失。

⑤=预测: 完成上述过程, 使用 validation set 进行预测, 并进行调优, 即即在 pre-training 后进行 fine-tuning 阶段。

⑥=①=数据



上海交通大学答题纸

(2022至2023 学年第 1 学期)

课程名称 机器学习

姓名 李呈翰

①: 数据收集处理: 收集大量人工编写的代码作为数据集, 并将其进行 one-hot 以及 word-embedding 处理, 将代码段赋予起始代码作为 train set 和 validation set

②: setup 的几个要素:

states: 某一时刻生成代码的结构变量, 以及当前处于函数信息

actions: 在编码到某一个 pos position 的时候, 接下来应该使用哪个 word 来继续编码。

rewards: 即时反馈 r_t , 即人工打的分: $r_t = \begin{cases} -1, & \text{出错} \\ 0, & \text{未出错} \end{cases}$

长期 reward 为 $R_t = r_t + \gamma R_{t+1} + \gamma^2 R_{t+2} + \dots$

policy: 在每个 state 下应采取怎样的编码 action。

③: 模型结构: 使用 value learning 方式进行学习, 即目标是找到一个 state 下最佳编码方式, 使用上课讲过的 Deep Q Network 进行模型训练。

④: 损失函数: $L(\theta) = E_{(s,a) \sim p} [\|r + \gamma \max_{a'} Q(s, a'; \theta) - Q(s, a; \theta)\|^2]$

即中 $Q(s, a; \theta)$ 为模型预测的当前最大长期分数,

$r + \gamma \max_{a'} Q(s, a'; \theta)$ 指的是模型在状态 s 下的 target 及 value

⑤: 训练: 使用梯度下降进行优化, 并每次先选定一个 old-target

并每过 C 步进行 old-target update 即: $\nabla L = E_{(s,a) \sim p} (r + \gamma \max_{a'} Q_{\text{old}}(s, a'; \theta) - Q(s, a; \theta)) \nabla Q(s, a; \theta)$

$\nabla L = E_{(s,a,r,s') \sim p} (r + \gamma \max_{a'} Q_{\text{old}}(s', a'; \theta) - Q(s, a; \theta)) \nabla Q(s, a; \theta)$, 每过 C 次更换 Q_{old} 。

⑥: 预测: 对于 validation set 进行代码的生成, 人工打分后看获取的长期分数是否足够高。

